

基于常识推理的未知环境零样本对象目标高效导航方法

程如意¹⁾ 郭斌¹⁾* 丁亚三¹⁾ 郝肇铁¹⁾ 於志文^{1),2)}

¹⁾(西北工业大学计算机学院, 西安 710072)

²⁾(哈尔滨工程大学, 哈尔滨 150001)

摘 要 在未知的环境中高效地导航到目标具身智能体执行下游任务的基础。现有的对象目标导航方法依赖于大量带标注的训练数据进行训练,但只在封闭对象集和特定环境中表现良好,存在样本效率低、泛化能力差的问题。本文提出一种低成本的零样本对象目标导航方法,探究智能体无需额外训练即可适应新物体和新环境的高效对象目标导航方法。受生物导航机制启发,本文提出一种模块化的导航方法,首先利用预训练的开放词汇目标检测模型提取场景语义标签并构建全局语义地图实现空间表征和记忆,同时基于预训练的大语言模型提取全局语义地图中的全局上下文信息从而推理未知区域的目标对象位置,最后通过路径规划输出导航动作。本文在 Habitat 模拟器中利用 Habitat-Matterport 3D (HM3D) 数据集以及 Matterport3D (MP3D) 数据集进行了实验验证。

关键词 具身智能; 零样本对象目标导航; 模块化导航方法; 路径规划; 常识推理

An Efficient Zero-Shot Object Goal Navigation Method in Unknown Environments Based on Commonsense Reasoning

CHENG Ru-Yi¹⁾ GUO Bin¹⁾ LIU Yan¹⁾ DING Ya-San¹⁾ YU Zhi-Wen^{1),2)}

¹⁾(School of Computer Science and Technology, Northwestern Polytechnical University, Xi'an 710072)

²⁾(Harbin Engineering University, Harbin 150001)

Abstract Efficient object goal navigation in unknown environments is fundamental for embodied agents to perform downstream tasks. Existing object goal navigation methods rely heavily on large amounts of annotated training data and perform well only within closed object sets and specific environments, exhibiting poor sample efficiency and limited generalization capabilities. This paper proposes a low-cost, zero-shot object-goal navigation method that enables agents to efficiently navigate to novel objects in new environments without additional training. Inspired by biological navigation mechanisms, this paper proposes a modular navigation approach. First, a pre-trained open-vocabulary object detection model is used to extract semantic labels from the scene and construct a global semantic map to achieve spatial representation and memory. Then, a large pre-trained language model is employed to extract global contextual information from the semantic map and reason about the potential location of the target object in unexplored areas. Finally, navigation actions are generated through path planning. We validate the proposed method in the Habitat simulator using the Habitat-Matterport 3D (HM3D) and Matterport3D (MP3D) datasets.

Key words embodied intelligence; zero-shot object goal navigation; modular navigation method; path planning; commonsense reasoning

1 引言

对象目标导航任务 (Object Goal Navigation) 需要智能体在给定环境中导航到特定的目标对象,然而其目标对象一般仅限于训练阶段预定义的类

别,任务示意图如图 1 所示。在现实世界中,智能体经常需要在未见过的环境中执行任务。例如,救援智能体可能需要在灾难现场寻找特定的物品,而这些环境和目标对象在训练阶段并未出现过。零样本对象目标导航 (Zero-Shot Object Goal Navigation) 能力可以使智能体快速适应新环境,提高任务执行

收稿日期: 年-月-日; 最终修改稿收到日期: 年-月-日。本课题得到国家杰出青年科学基金项目(62025205), 国家自然科学基金青年项目(No.62302017), 国家自然科学基金项目(No.62032020)资助。程如意, 女, 2003年生, 本科生, 计算机科学与技术专业。E-mail: chengruyi@mail.nwpu.edu.cn。郭斌 (通信作者), 男, 1980年生, 博士, 教授, CCF高级会员(E20019107S), 主要研究领域为普适计算、移动群智感知。E-mail: guob@nwpu.edu.cn。丁亚三, 男, 1995年生, 博士, CCF专业会员(95532M), 主要研究领域为人机物融合群智计算、智能物联网。Email: yasanding@nwpu.edu.cn。郝肇铁, 男, 1999年生, 博士研究生, 主要研究领域为普适计算、移动群智感知。E-mail: haozhaotie@mail.nwpu.edu.cn。於志文, 男, 1977年生, 博士, 教授, CCF高级会员(E200008324S), 主要研究领域为普适计算、社会感知计算。

第1作者手机号码:19829826107, E-mail: chengruyi@mail.nwpu.edu.cn

的效率和成功率,同时减少对大量标注数据的依赖。零样本对象目标导航任务,引入了零样本学习的概念,即导航智能体无需额外训练即可适应新物体和新环境,要求智能体在没有见过目标对象具体实例的情况下,在未知环境中能够理解目标对象类别的语义信息,找到目标对象类别的实例。



图1 对象目标导航任务示意图

零样本对象目标导航任务对智能体提出了诸多挑战。首先是环境的未知性与复杂性,智能体需要在未知环境中探索并定位目标物体。室内环境呈现出高度多样的空间结构(如客厅、卧室等),并包含各类家具、装饰物等。智能体不仅需辨别功能区域,还需记忆环境中的相对位置关系。其次,零样本条件下,智能体缺乏目标对象实例和导航环境的直接训练,需要在环境信息不完全或感知模糊的情况下,选择合适的探索方向,从而实现对可能目标区域的优先探索。为了能够在不同环境中均维持较好的导航性能,模型需要具有较好的泛化能力。现有的对象目标导航模型在面对多样化的未知目标类别和复杂环境时,分布外泛化性能仍存在瓶颈。主要原因在于现有方法依赖于训练集中出现的场景分布与目标对象,从而在跨环境、跨类别目标对象导航过程中效果大幅下降。

生物导航机制具有高度的灵活性、适应性和鲁棒性,能够应对复杂多变的环境。生物导航依赖于复杂的空间记忆机制。空间表征和记忆不仅可以存储并帮助随后回忆起有助于导航的环境信息,还可以帮助规划新的路径。此外,人类的导航过程离不开语义记忆。在未知的陌生环境中人类平时积累的知识 and 规律可以帮助人类探索任何新的环境,并能高效地找到目标对象。例如,当去朋友家做客想要找到碗筷时,会优先走到厨房内进行寻找,而不是卧室等其他地方。

受此启发,在零样本对象目标导航任务中,成功导航到目标对象可以依赖于两种关键能力:(1)场景理解和记忆,即识别环境中的物体和区域并对已探索场景进行表征和记忆;(2)推理和决策,即根据已有的知识以及空间记忆对目标对象的大致位置进行推理并对后续优先探索方向进行决策。具

体而言,为了在一个未知的环境中有效识别具有未知外观的目标对象,智能体需要对已探索环境进行理解和记忆,利用对于典型室内环境的常识来指导其高级搜索策略,最终通过低级行动规划无碰撞的准确到达目标对象。

如今大语言模型(Large Language Model, LLM)储备的知识以及常识推理能力可以为智能体提供充分的室内场景先验知识来指导智能体的探索。例如,询问通义千问大模型“椅子通常位于房子的哪个位置?”,可以得到回答:“餐厅、客厅、卧室、办公室、厨房”,这可以为智能体的探索提供大致的方向。语言-图像预训练模型 Grounded Language-Image Pre-training^[1](GLIP)支持开放词汇物体检测,支持指定任何感兴趣的目标对象(即使是使用描述性的自然语言)。

基于上述背景,为解决现有零样本对象目标导航的问题,本文由生物导航机制启发,提出了“基于常识推理的未知环境零样本对象目标高效导航方法”,模仿生物导航的空间记忆机制与人类导航基于语义记忆的推理过程,提升导航智能体在未知环境的适应能力。本文的工作如下:

1) 基于开放词汇目标检测的语义地图实时构建,这为后续导航奠定基础。基于场景的 RGB-D 图像,使用语言-图像预训练模型 GLIP 提取语义标签,使用深度信息完成三维点云构建,将语义信息和三维点云映射到三维体素网格中,再生成二维语义地图,随后使用地图融合机制实时更新语义地图。

2) 基于 LLM 常识推理的中期目标选择策略,通过中期目标选择引导智能体探索未知环境。利用大语言模型对语义地图存储的空间记忆进行常识推理,对目标对象和已探索区域中物体在空间上的相近程度进行预测,并选择中期目标来引导智能体探索环境并寻找目标对象。

3) 对到达中期目标的路径进行规划并动态避障。基于选定的中期目标以及语义地图记录的空间信息利用快速行进算法进行路径规划,并完成智能体导航过程中的避障。

为验证所提方法有效性,本文在 Habitat 模拟器中利用 Habitat-Matterport 3D (HM3D) 数据集以及 Matterport3D (MP3D) 数据集进行了广泛的实验。本文方法在 HM3D 和 MP3D 数据集上成功率 SR 分别达到 42.6% 和 27.6%,成功率加权路径长度 SPL 分别达到 20.3% 和 7.7%,与其他基准方法对比,本文方法在 SR 和 SPL 上均有提升,本文方法未针对导航环境和目标对象进行训练,体现出较好的零样本能力。

2 相关工作

2.1 端到端对象目标导航方法

端到端的对象目标导航方法指将智能体的观察通过策略网络直接映射到动作的方法，这些方法通常基于强化学习或模仿学习。其架构如图2所示。强化学习（Reinforcement Learning, RL）的核心思想是让智能体在环境中采取行动，根据环境的反馈来学习最优的行为策略，从而在长期中获得最大的累积奖励。将强化学习应用到对象目标导航方法时，智能体需要从传感器（RGB-D 相机、GPS 等）和目标对象的标签接收信息，并通过从中提取特征并将其输入策略网络来决定智能体下一步要采取的行动。然而基于强化学习的方法往往面临着泛化不佳或过度拟合、稀疏奖励和样本效率低下的问题。为了克服泛化不佳或过度拟合问题，一些方法引入了元学习。ULTRA^[2]框架通过无监督强化学习从无标注的环境中学习可转移的元技能，然后在有标注的环境中快速适应视觉导航任务。THDA^[3]方法指出过度拟合是端到端对象目标导航方法性能不佳的关键原因。该方法通过数据增强技术，将3D扫描的家用物品随机插入到现有的3D环境中，从而显著增加了训练布局的多样性。为了解决稀疏奖励挑战，HIEM^[4]方法提出了一个分层策略，通过增加子目标奖励即当智能体达到子目标状态时也给予正奖励，来缓解这种稀疏奖励问题。一些端到端对象目标导航方法基于模仿学习来实现。Habitat-web^[5]收集了80k个人类演示数据，旨在通过模仿人类演示来训练智能体完成具身任务。

然而这些方法通常只适用于它们所训练的封闭对象集以及与训练场景相似的环境，与此同时，模拟环境与现实世界之间的域偏移问题依然显著。此外，端到端学习的对象目标导航方法需要大量的计算资源和时间开销，收集大量的训练数据仍然困难。




图2 端到端及模块化对象目标导航方法架构示意图

2.2 模块化对象目标导航方法

为应对端到端对象目标导航方法存在的问题，

模块化对象目标导航方法保留了基于概率模型的传统导航方法的分层架构，以数据驱动的子任务学习模块替代传统方法中的特定子任务分析模块。其架构见图2。该方法通过将复杂导航任务分解为若干子问题，在工程实现层面展现出更低的复杂度与更高的可解释性优势。其中学习模块通过直接监督学习机制进行训练，相较于端到端学习范式展现出更优的样本利用效率。模块化方法通常包括一个表征环境的建图模块、一个生成中期目标的策略模块以及一个导航至中期目标的路径规划模块。

根据建图模块的地图表示，模块化对象目标导航方法的建图模块大致可分为两种：基于网格地图表示和基于拓扑图或其他图形的表示。使用网格地图的工作显式或隐式地将部分观察到的3D环境投影到自上而下的2D网格地图上。例如，SemExp^[6]的语义建图模块首先使用MaskRCNN^[7]将当前帧进行语义分割，再投影到一个自上而下的语义网格局部地图，该地图被累积以获得全局语义网格地图。一些作品探索了拓扑地图或图形来表示环境。VLV^[8]方法在导航过程中，构建一个拓扑图，图中的节点代表智能体在环境中的位置，边代表智能体可以移动的方向。一些工作提出在输入到策略模块之前预测完整的地图进而预测目标对象的位置。L2M^[9]方法通过两阶段分割模型预测地图中未观察区域的语义信息。首先预测占用信息，然后基于预测的占用信息预测最终的语义区域。PONI^[10]训练了一个势函数网络在语义地图的基础上进行几何和语义推理，并采样一个中期目标位置以探索目标物体。然而上述方法依旧需要针对特定环境使用大量注释数据进行训练，并且在应对开放词汇目标对象时仍然具有局限性。

2.3 生物导航的空间记忆机制

生物导航会利用复杂的空间记忆机制。空间记忆的目的是编码、存储、识别和回忆关于环境及其内部物体的空间信息^[11]。表征方式可以根据所使用的参考系进行分类。自我中心表征以自我中心（主观视角）为参考系对空间信息进行表示。非自我中心表征以外部世界参考物为参考系表示相对于环境地标或边界的空间信息。

记忆可以看作是对信息编码、存储以及提取检索的过程，包括情境记忆和语义记忆。情景记忆涉及到与经历该事件相关的特定细节，包括其空间和时间背景等。而语义记忆涉及到关于世界的事实，是指一般知识和规律，与特定的时间和地点等细节无关。人类导航过程中离不开记忆，特别是语义记忆。这些知识和事实能够帮助人类进行高效探索和路径规划。语义记忆中存储的不同地点之间的关系，可以帮助规划出合理的路径。例如，我们知道从家到超市的路线，因为我们在记忆中存储了沿途的关键地标（如十字路口、商店招牌等）。除此之

外, 语义记忆中的知识和规律可以帮助我们在陌生环境中高效探索。例如, 我们知道商场的一楼通常有入口和主要的店铺, 而楼上可能有餐厅和娱乐设施。这种理解使我们能够在复杂的环境中有效地进行探索和导航。

生物的空间记忆机制, 对于智能体导航有着重要启发作用。在智能体的自主导航过程中应该记住已经访问过的地方, 否则会导致它反复前往相同的位置, 除此之外也需要先验知识来指导智能体的自主探索。一些端到端对象目标导航方法使用长短期记忆网络^[12]将记忆隐式编码到网络中。有些方法则使用显式的记忆模块来提高导航效率。Mezghan^[13]等人为了利用智能体的历史观测信息, 引入了外部记忆机制。通过自监督学习训练一个状态嵌入网络, 将环境中的位置映射到一个嵌入空间。Kwon^[14]等人则同时使用图神经网络和一种称为视觉图记忆(VGM)的显式记忆。VGM是一个图结构, 包含节点(顶点)和边, 节点代表环境中的位置, 每条边表示两个节点之间是否可达。模块化对象目标导航方法通常编码关于环境语义信息的地图包括网格地图和基于拓扑图或其他图形的地图来完成空间记忆。CMP^[15]方法将认知建图和路径规划结合起来, 将智能体观察到的第一人称视角的图像信息整合到一个自上而下的二维信念地图中, 这相当于对于环境构建自上而下视角的自我中心地图。MEM2EGO^[16]除使用一个自上而下的2D地图记忆已探索区域的障碍物和边界外, 还对智能体已经访问过的地标做记录并存储地标描述。

3 方法

3.1 任务建模

为验证本文方法的泛化性, 本文方法未采用与目标对象相关的标签进行训练, 亦未对导航环境进行针对性训练。具体任务设置如下:

给定一组未知的环境 $\{E_{new}\}$ 和一组新的目标对象 $\{O_{new}\}$, 智能体需要在 $\{E_{new}\}$ 中针对 $\{O_{new}\}$ 执行对象目标导航任务。

智能体需要在一个从未探索过的环境中, 找到一个以语义信息指定的物体类别的一个实例(例如‘椅子’、‘床’)。智能体在每个时间步 t 会获得一个以自我为中心的RGB-D图像 I_t 作为观察, 以及当前智能体的位姿 p_t , p_t 来自于传感器观测 (x, y, θ) , (x, y) 为智能体当前位置, θ 对应于智能体当前旋转角度与起始旋转角度在垂直轴上的角度差。智能体可以从动作空间中选择动作进行探索, 动作空间是一个有限集合, 包含四个离散动作, 可以表示为 $A = \{a_0, a_1, a_2, a_3\}$, 其中 a_0 为停止动作, 用于终止导航过程, a_1 为向前移动, a_2 为左转动作

a_3 为右转动作。智能体在移动500步内并且距离目标物体1米范围内执行停止动作, 且可以从停止位置观察到该物体(排除距离很近但隔着障碍物的情况), 则算任务成功, 否则任务失败。

3.2 方法整体架构

本文所提方法整体框架如图3所示。首先使用语言-图像预训练模型GLIP进行目标检测获取智能体当前步观察中的物体语义信息。之后使用RGB-D图像中的深度信息构建三维点云, 将上述结合智能体的位姿输入语义建图模块更新自上而下的全局语义地图。根据当前导航场景下的目标对象语义类别, 以及全局语义地图记录的已观察到的空间语义信息, 利用大语言模型的常识推理能力对目标对象可能出现的位置进行概率预测。中期目标的位置根据预测结果和智能体当前的位置进行选择。根据中期目标的位置, 路径规划模块规划到达中期目标的路径, 并输出智能体的下一步动作, 智能体的观察和位姿随智能体的移动更新。

本文方法将分为三个部分做介绍: 基于开放词汇目标检测的语义地图实时构建、基于常识推理的中期目标选择策略构建、路径规划与动态避障策略构建。语义地图构建过程将在第3.3节中回顾。第3.4节中介绍了如何选择中期目标进而实现自主探索。第3.5节描述了根据中期目标进行路径规划的局部策略。




图3 本文方法整体架构

3.3 基于开放词汇目标检测的语义地图实时构建

本文的语义建图模块遵循了Semexp方法相似的流程。本方法设置的语义图 m_t 具有 $(N + 4)$ 个通道。通道1和2分别表示障碍物地图和已探索区域。通道3和4包含智能体当前位置及所有过去的位置, 其余的 N 个通道代表 N 个语义类别, 记录环境中每个语义类别的物体的位置。本文建图方法示意图如图4所示。




图4 语义地图实时构建方法总体架构示意图




图6 模拟环境中使用 GLIP 进行目标检测示意图

3.3.1 场景语义标签提取

本文方法使用图像-语言预训练模型 GLIP 进行物体检测,与现有方法限于训练过的固定类别集的模型(如 Mask-RCNN)不同, GLIP 支持开放词汇目标检测。得益于大规模图像-文本预训练, GLIP 它不仅能识别使用自然语言定义的对象,还能将其与相关对象区分开来。因而使用 GLIP 可以识别和定位任意语言描述的物体,并且它易于推广到不同的环境和目标对象。

GLIP 可以生成大量图像-文本配对数据的基础框,因而提供了可以定位智能体观察到的 RGB 图像中的物体的边界框, GLIP 的输出可以表示为公式(1):

$$\{o_{t,i}, b_{t,i}\} = GLIP(I_t, G_o) \quad (1)$$

其中 I_t 为时间步 t 智能体观测到的场景的 RGB 图像, G_o 是需要检测的物体类别集合, GLIP 会输出检测到物体的语义标签 $o_{t,i}$ 和这些物体在图像中对应区域的边框 $b_{t,i}$ 。根据 GLIP 的输出,提取智能体观察中的物体语义类别信息,将语义信息和定位的边框记录下来用于后续语义地图的构建,图 5 展示了针对不样式的杯子, GLIP 能准确识别并且能够正确区分,同时支持检测自然语言描述的物体,具体输入给 GLIP 的提示为“Find the cup that has a panda design or pattern on its surface. the red cup”, GLIP 输出对应的定位框以及相应的置信度“the red cup: 0.86”和“the cup: 0.82”。图 6 展示了使用 GLIP 对模拟环境中智能体的 RGB 观察进行目标检测。



图5 GLIP 根据自然语言描述进行识别示例图

3.3.2 语义地图的构建与更新

(1) 基于深度图像及语义标签的自我中心语义地图生成

利用当前步观测到的深度图像生成以智能体相机为坐标原点的相机坐标系下的三维点云。然后通过考虑相机的仰角、传感器高度和相机位置,将三维点云从相机坐标系转换到智能体以自我为中心的自我中心坐标系。再将转换后的三维点云和由 GLIP 得到的语义信息使用线性插值的方法映射到三维体素网格中,对三维体素网格在高度方向上聚合生成语义地图的多个通道,即可得到自上而下的二维语义地图,此语义地图是智能体视角下的自我中心语义地图。

(2) 局部—全局语义地图更新

将智能体当前步观测得到的自我中心语义地图根据智能体的姿态转换到非自我中心的全局坐标系中,并且为了更好的利用上下文信息,每一步的局部语义地图会和上一时刻的局部语义地图融合,这样就通过累积的方式形成了全局坐标系下的随智能体动作实时更新的局部语义地图,设置智能体走一定步数后就根据智能体在全局语义地图中的位置,将全局坐标系下的局部语义地图更新到全局语义地图中。通过多尺度的语义地图设置,在实现语义地图实时更新的同时,减少计算量。

语义地图对空间的几何信息和语义信息进行了表征和存储,通道 1 的障碍物地图记录环境中物体的占用信息和几何信息,而语义类别对应的通道记录对应障碍物的语义标签。全局语义地图是后续预测目标对象的位置并进行路径规划的基础。

3.4 基于常识推理的中期目标选择策略构建

3.4.1 基于 LLM 常识推理的目标对象位置概率预测

根据智能体附近全局语义地图包含的场景信息,获取智能体已观察到的物体的语义类别,根据物体语义类别和目标对象语义类别,生成用于 LLM 的提示 (Prompt),提示要求 LLM 给出场景中物体和目标对象在空间上相近的概率,并以字典格式返回结果。

(1) 问题建模:

定义语义类别集合 $C = \{c_i\}_{i=0}^n$, c_i 为语义类别编号对应于语义地图中设置的语义类别的编号,定义类别名称映射 $f_{name}: C \rightarrow T$, T 为语义类别名称集

合, 将语义类别编号与语义类别名称相对应(例如: 编号 0 对应‘椅子’), 对于当前的全局语义地图 M_{sem} , 提取存储的已观察场景中的物体语义类别编号集合 C_{map} , 根据物体语义类别和目标对象语义类别 $f_{name}(c_{target})$, 生成 prompt, 利用 LLM 预测场景中物体与目标对象之间的空间关联概率。

(2) prompt 生成:

给定全局语义地图中的物体类别: $\{f_{name}(c_j | c_j \in C_{map})\}$, 目标对象类别为 $\{f_{name}(c_{target})\}$, 请以字典的形式输出各物体类别与目标对象类别的空间关联概率。

LLM 输出: $\{c_i : p_i\}$ 。

根据得到的概率预测以及语义地图构建目标对象位置概率预测图, 在全局语义地图中物体类别编号对应处填充上由 LLM 预测的概率, 同时进行掩码操作确保只对未探索区域进行预测更新避免智能体重复探索, 得到与语义地图尺寸匹配的目标对象位置概率预测图。实验过程中智能体利用 LLM 进行常识推理的具体过程如图 7 所示。

Prompt: Given the object categories in the map: chair, tv_monitor, and the target category plant, provide the probability of each category belonged to chair, tv_monitor, being closer to the target category. Format the response as a dictionary with keys as object categories and values as probabilities. Only give me the dictionary, no other words.
Response: {"chair": 0.3, "tv_monitor": 0.7}

图 7 实验过程中使用 LLM 获取预测概率

3.4.2 中期目标位置选择

需要基于语义地图、目标对象位置概率预测图生成最优的中期目标位置。基于语义地图第一通道的障碍物地图和第二通道的探索地图, 使用快速行进算法^[17] (Fast Marching Method) 计算从当前位置到其他所有可通行点的最短距离场, 并由此得到测地距离图, 结合目标对象位置概率预测图和测地距离图计算具有最大探索价值的位置, 作为新的中期目标位置。

首先使用快速行进算法计算从智能体当前位置到每个候选中期目标位置的最短路径测地距离, 测地距离考虑了障碍物的存在。

结合目标对象位置预测概率和智能体到对应位置的测地距离, 中期目标选择公式如下:

$$goal_{mid} = \arg \max_{(i,j)} \exp(-d_t(i,j)) P_t[i,j] \quad (2)$$

其中 $d_t(i,j)$ 是从当前位置到位置 (i,j) 的测地距离, $P_t[i,j]$ 为由 LLM 推理得到的目标对象位于位置 (i,j) 的预测概率。

如图 8 示, 使用快速行进算法计算智能体到其他位置的测地距离, 测地距离图中蓝色越深的位置距离智能体的测地距离越小, 注意到全局语义地图中灰色的表示障碍物的部分在测地距离图中的颜色为白色, 意味着距离为无穷大, 这一设置是为了

在路径规划过程中考虑并避开障碍物, 避免因为障碍物的干扰导致智能体做出错误的路径规划。



图 8 使用快速行进算法实时计算测地距离

3.5 路径规划与动态避障策略构建

为到达中期目标智能体需要进行路径规划, 计算得出下一步的航点。根据动态构建的障碍物地图, 排除不可通行区域, 使用 FMM 算法计算从中期目标区域到每个可通行点的最短距离, 根据智能体的步长从智能体下一步可以到达的区域中选择一个到中期目标位置和到智能体位置都近的航点。具体而言, 本方法依据一个比值 r_t 来选择航点:

$$r_t = \frac{Ds_t}{ds_t} \quad (3)$$

Ds_t 表示从中期目标位置到以当前智能体位置为圆心以智能体步长为半径范围内点的最短路径距离场。 ds_t 表示从智能体当前位置到 Ds_t 中每个点的欧几里得距离。选择比值 r_t 最小的点作为下一步的航点。

4 实验

4.1 实验平台及数据集

4.1.1 实验平台

本文所有实验均在 Habitat^[18] 模拟器中完成。Habitat 是一个具身人工智能研究平台, 包括 Habitat-Sim 和 Habitat Lab, Habitat-Sim 是一个高性能的 3D 模拟器。Habitat-Lab 是一个模块化高级库。

4.1.2 实验数据集

Habitat-Matterport 3D^[19] (HM3D) 是一个大规模的数据集, 包含来自多种现实地点的 1000 个涵盖了整个建筑物的 3D 重建。HM3D 数据集的验证集包含 2000 个测试场景(episode), 设置有 6 个目标对象类别和 20 个 3D 扫描环境。

Matterport3D^[20] (MP3D) 是一个包含 90 栋建筑规模场景的大型 RGB-D 数据集, 提供完整房屋的扫描数据数据集。本文使用的 MP3D 数据集的验证集包含 11 个扫描环境中的 2195 个测试场景, 涉及 21 个目标对象类别。

4.2 实验设置及评估指标

4.2.1 实验设置

在实验过程中使用阿里通义大模型 Qwen-plus 进行常识推理。

智能体被建模为半径 0.18m 和高度 0.88m 的理想化圆柱体。它配备了 RGB-D 相机和 GPS+Compass 传感器, RGB 相机具有 79° 水平视野, 分辨率为 640×480, 深度相机从 0.5m 到 6m。GPS+Compass 传感器提供智能体相对于起始位置(原点)和起始航向(0°)的相对位置(x,y,z)和相对航向信息 θ 。智能体的动作空间包括“前进 0.25m”、“左转 30°”、“右转 30°”和“停止”。

4.2.2 评估指标

(1) 成功率(SR):

$$SR = \frac{\text{成功的测试场景数量}}{\text{总测试场景数量}} \quad (4)$$

SR 只考虑智能体最终的停止点到目标对象的距离以及智能体的探索步数是否符合要求, 因而无法衡量路径的效率, 所以引入成功率加权路径长度这一评估指标。

(2) 成功率加权路径长度(SPL):

$$SPL = \frac{1}{N} \sum_{i=1}^N S_i \frac{d_i}{\max(p_i, d_i)} \quad (5)$$

S_i 表示第 i 次实验是否成功, 成功则取值为 1, 失败则为 0, d_i 是从智能体初始位置到目标对象的理想最短路径长度, p_i 是智能体实际导航的路径长度。

SPL 的取值范围为[0,1], SPL 既衡量成功率(SR), 又考虑智能体的探索路径是否高效, 智能体到达目标对象走过的路径长度越短, 越接近理想最短路径长度, SPL 的值就越大越接近 1, SPL 从而一定程度上反映了智能体的探索效率。

(3) 软成功率加权路径长度(SoftSPL)^[21]:

$$SoftSPL = \frac{1}{N} \sum_{i=1}^N (1 - \frac{dt_i}{d_i}) \frac{d_i}{\max(p_i, d_i)} \quad (6)$$

dt_i 代表智能体在测试实例结束, 执行停止动作时距离目标对象的距离, d_i 是从智能体初始位置到目标对象的理想最短路径长度, p_i 是智能体实际导航的路径长度。

SoftSPL 是 SPL 的较软版本, 根据智能体停止时到达目标的进展(即使成功率为 0)来衡量效率。SR 和 SPL 都仅依赖于二元指标 0 和 1 来评估成功的测试场景, 无法提供任何关于失败测试场景的信息。因此为了考虑失败的测试场景的情况, 在消融实验中本文引入了 SoftSPL 评估指标。

4.3 实验结果与对比

4.3.1 对比方法介绍

(1) 端到端方法:

ProcTHOR^[22]: 论文构建 ProcTHOR-10K 数据集, 包含 10000 个通过程序化生成的交互式房屋用

于训练模型。模型仅依赖 RGB 图像作为输入, 不使用深度传感器或其他模态的输入。这里我们与其零样本设置下的评估结果做对比, 即模型仅在 ProcTHOR-10K 上预训练, 不使用下游基准任务的训练数据, 直接在测试数据集上进行评估。

ZSON^[23]: 该方法核心在于将图像目标导航(ImageNav)和对象目标导航(ObjectNav)统一到一个语义嵌入空间中, 从而实现零样本的对象目标导航。首先在大规模未标注的 3D 环境中针对图像目标导航任务训练智能体。目标图像通过 CLIP 模型^[24]的图像编码器转换为语义目标嵌入。零样本对象目标导航任务中, 将自然语言描述的目标对象通过 CLIP 的文本编码器转换为语义目标嵌入。使用 CLIP 模型将图像和文本目标统一到一个语义嵌入空间中使得智能体可以无缝地从图像目标导航迁移到对象目标导航。

(2) 模块化方法:

ANS^[25]是一个模块化强化学习策略, 模型由三个组件组成: 神经 SLAM 模块、全局策略和局部策略。神经 SLAM 模块含两个主要部分: 地图构建器和位姿预测器。地图构建器生成二维空间地图, 预测障碍物和已探索区域。位姿预测器则用于估计智能体的位姿变化。全局策略通过一个卷积神经网络来实现, 使用强化学习训练, 奖励函数是基于智能体探索到的新区域的增加量, 通过最大化覆盖面积的方式进行探索。局部策略负责将全局策略规划的中期目标转化为具体的导航动作。

CoW^[26]方法同我们的方法一样是一个零样本方法。CoW 方法以第一人称的 RGB-D 图像和用语言指定的目标物体作为输入。当智能体移动时, 它会使用 RGB-D 观测和位姿估计来更新一个自上而下的地图。CoW 包括一个探索策略和一个零样本目标定位模块。使用基于边界的探索策略进行探索, 在移动过程中, 智能体利用目标定位模块和地图来跟踪对目标物体位置的置信度。当置信度超过某个阈值时, 它会规划前往目标位置的路径, 并执行停止动作。

PixelNav^[27]: PixelNav 是一种纯基于 RGB 图像的导航策略, 不依赖地图或深度信息。其核心思想是将导航目标表示为图像中的像素点, 以这个像素点为目标, 执行一系列基本动作, 引导智能体导航至目标位置。该方法使用 LLamaAdapter 模型^[28]将图像转换为文本, 并设计分步提示指导 GPT-4 定位智能体的位置。为了分配一个像素作为目标, 引入了两个额外的基础模型, 即 GroundingDINO^[29]模型和 SAM^[30]模型来获取分割掩码。一旦 LLM 提出目标对象, 对象掩码的中心点将被分配为低级导航策略的像素目标。PixNav 训练一个基于 Transformer 的网络, 以历史图像序列和目标像素点为输入, 输出最优动作, 并使用 Habitat-Lab 模拟器与 HM3D

数据集生成超过 10 万条导航轨迹训练该网络。

4.3.2 实验结果分析

对比实验结果如表 1 所示, 其中“环境训练”是指是否有在 MP3D 或 HM3D 数据集的训练集上做训练, 图 9 为智能体使用本方法在场景中完成零样本对象目标导航的一个过程示例, 该测试场景的目标对象为‘床’, 图 10 将对对比实验结果绘制成柱状图, 更加直观。

表 1 对比实验结果

方法	环境 训练	MP3D		HM3D	
		SPL	SR	SPL	SR
ProcTHOR-ZS	否	-	-	0.077	0.132
ZSON	是	0.048	0.153	0.126	0.255
ANS	否	0.092	0.273	-	-
PixelNav	是	-	-	0.205	0.379
CoW	否	0.037	0.074	-	-
本文方法	否	0.077	0.276	0.203	0.426

尽管 ProcTHOR-ZS 方法在 ProcTHOR 数据集上进行了预训练, 并可以直接适应其他数据集, 但在 HM3D 数据集上的表现严重下降, 其 SPL 仅为 0.077, SR 为 0.132。相比之下, 本文的方法在 HM3D 数据集上表现明显更为出色, SPL 和 SR 分别为 0.203 和 0.426。尽管 ZSON 在图像目标导航任务中使用 HM3D 数据集训练智能体, 其在 HM3D 测试集上 SPL 为 0.126, SR 为 0.255, 而本文方法在 HM3D 数据集上大幅超越了 ZSON, 在 SR 和 SRL 上分别提高了 67.0%和 61.1%。在 MP3D 数据集上本文方法在 SR 和 SPL 上相比于 ZSON 分别提高了 80.3%和 60.4%。相比于上述两种端到端对象目标导航方法, 本文的方法在未针对任何导航环境进行训练的情况下, 仍然能够更好的完成导航任务, 在两个数据集上表现均较好。

对于所对比的模块化对象目标导航方法, 在 MP3D 数据集上本文方法在 SR 和 SPL 上均超越了 ANS 方法, 同时本文方法支持开放词汇目标对象, 可以更好的适应未见过的新的目标对象。在 MP3D 数据集上, CoW 方法 SPL 为 0.037, SR 为 0.074, 而本文方法分别达到了 0.077 和 0.276, 分别提高了 108%的 SPL 和 273%的 SR。这表明相比于同样致力于零样本能力的 CoW 方法, 我们的方法在零样本对象目标导航任务中具有更强的能力。本文方法和 PixelNav 方法都支持开放词汇目标对象导航也都使用了 LLM 进行推理, 本文方法在 HM3D 测试集上的成功率超越了 PixelNav, 提高了 12.4%。PixelNav 方法专门使用 HM3D 数据集中 10 万条导航轨迹训练其局部策略网络而本文方法路径规划策略不需要训练, 减少了资源消耗, 降低了计算成

本。在 SPL 指标上, 本文方法仅比 PixelNav 低 0.002。在探索策略上 PixelNav 使用 LLM 直接选定下一步的探索房间并且规划路径, 本文方法则是让 LLM 输出观察到的物体和目标对象之间在空间上相近的概率, 并结合这些观察到的物体与智能体当前位置的距离选定下一步的中期目标, 更合理利用了 LLM 的常识推理能力, 同时更具有可解释性。



图 9 从编号 1 到编号 6 对应的图片为智能体寻找目标对象‘床’的过程




图 10 不同方法在 MP3D 和 HM3D 数据集上的测试表现

4.4 消融实验

本文选取了 HM3D 数据集上 500 个测试场景做消融实验, 结果如表 2 所示, 图 11 是利用消融实验结果绘制的散点图。本文评估的方法包括不使用距离加权而是仅使用 LLM 预测的概率进行中期目标选择的方法以及完全不使用目标对象位置概率预测而是始终导航到最近的未探索位置的方法, 这相当于使用基于边界的探索策略^[31]。对于这种智能体, 将最小距离限制为 3 米, 以防止过度来回移动。在没有距离加权的条件下, 智能体的表现较本文方法差, 因为它可能会忽略更近的目标对象而选择更远的中期目标, 即使目标对象可能在尚未探索的更近的区域。不使用目标对象位置预测概率时, 智能体的表现也较差, 因为它浪费时间在无用的位置上搜索。不使用距离加权的方法相比于不使用目标对象位置概率预测的方法虽然在 SR 和 SPL 上的表现都较差, 但 SoftSPL 却表现得更好, 说明考虑上失败的测试场景, 使用本文方法中目标对象位置概率预测的探索策略能够帮助智能体更高效地寻找目标对象。

本文将利用完整全局语义地图进行预测的效果, 与仅使用单帧 RGB-D 观测构建的自我中心的

语义地图进行预测的效果进行对比。由结果可以看出使用全局语义地图进行预测比仅使用单帧RGB-D观测进行预测的SR和SPL都显著更好，因此认为构建全局语义地图利用全局上下文信息能够提升导航的效率，同时也表明构建全局的空间记忆在零样本对象目标导航任务中的重要性。

表2 消融实验结果

方法	SR	SPL	SoftSPL
不使用距离加权	0.298	0.147	0.220
不使用目标概率预测	0.358	0.160	0.217
仅使用单帧观测预测	0.408	0.178	0.237
本文方法	0.442	0.215	0.280




图11 消融实验各方法结果对比

5 结论

本文针对零样本对象目标导航任务提出了“基于常识推理的未知环境零样本对象目标高效导航方法”，使得智能体能在未知环境中根据目标对象语义类别，找到目标对象的一个实例。本文方法是一个零样本方法，不针对封闭的对象集和特定环境做训练，支持开放词汇目标对象。本文在Habitat模拟器上利用HM3D数据集和MP3D数据集进行了对比实验和消融实验，验证了本文方法的有效性、先进性以及良好的泛化性。

致谢

本文得到国家杰出青年科学基金项目(No.62025205)、国家自然科学基金青年项目(No.62302017)、国家自然科学基金项目(No.62032020)资助。

参考文献

- [1] Li L H, Zhang P, Zhang H, et al. Grounded language-image pre-training[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10965-10975.
- [2] Li J, Wang X, Tang S, et al. Unsupervised reinforcement learning of transferable meta-skills for embodied navigation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 12123-12132.
- [3] Maksymets O, Cartillier V, Gokaslan A, et al. Thda: Treasure hunt data augmentation for semantic navigation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 15374-15383.
- [4] Ye X, Yang Y. Efficient robotic object search via hiem: Hierarchical policy learning with intrinsic-extrinsic modeling[J]. IEEE robotics and automation letters, 2021, 6(3): 4425-4432.
- [5] Ramrakhya R, Undersander E, Batra D, et al. Habitat-web: Learning embodied object-search strategies from human demonstrations at scale[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5173-5183.
- [6] Chaplot D S, Gandhi D P, Gupta A, et al. Object goal navigation using goal-oriented semantic exploration[J]. Advances in Neural Information Processing Systems, 2020, 33: 4247-4258.
- [7] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [8] Chang M, Gupta A, Gupta S. Semantic visual navigation by watching youtube videos[J]. Advances in Neural Information Processing Systems, 2020, 33: 4283-4294.
- [9] Georgakis G, Bucher B, Schmeckpeper K, et al. Learning to map for active semantic goal navigation[J]. arXiv preprint arXiv:2106.15648, 2021.
- [10] Ramakrishnan S K, Chaplot D S, Al-Halah Z, et al. Poni: Potential functions for objectgoal navigation with interaction-free learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 18890-18900.
- [11] Madl T, Chen K, Montaldi D, et al. Computational cognitive models of spatial memory in navigation space: A review[J]. Neural Networks, 2015, 65: 18-43.
- [12] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [13] Mezghan L, Sukhbaatar S, Lavril T, et al. Memory-augmented reinforcement learning for image-goal navigation[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2022: 3316-3323.
- [14] Kwon O, Kim N, Choi Y, et al. Visual graph memory with unsupervised representation for visual navigation[C]//Proceedings of

- the IEEE/CVF international conference on computer vision. 2021: 15890-15899.
- [15] Gupta S, Davidson J, Levine S, et al. Cognitive mapping and planning for visual navigation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2616-2625.
- [16] Zhang L, Liu Y, Zhang Z, et al. Mem2ego: Empowering vision-language models with global-to-ego memory for long-horizon embodied navigation[J]. arXiv preprint arXiv:2502.14254, 2025.
- [17] Sethian J A. A fast marching level set method for monotonically advancing fronts[J]. proceedings of the National Academy of Sciences, 1996, 93(4): 1591-1595.
- [18] Savva M, Kadian A, Maksymets O, et al. Habitat: A platform for embodied ai research[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 9339-9347.
- [19] Ramakrishnan S K, Gokaslan A, Wijmans E, et al. Habitat-matterport 3d dataset (hm3d): 1000 large-scale 3d environments for embodied ai[J]. arXiv preprint arXiv:2109.08238, 2021.
- [20] Chang A, Dai A, Funkhouser T, et al. Matterport3d: Learning from rgb-d data in indoor environments[J]. arXiv preprint arXiv:1709.06158, 2017.
- [21] Datta S, Maksymets O, Hoffman J, et al. Integrating egocentric localization for more realistic point-goal navigation agents[C]//Conference on Robot Learning. PMLR, 2021: 313-328.
- [22] Deitke M, VanderBilt E, Herrasti A, et al. ProcTHOR: Large-Scale Embodied AI Using Procedural Generation[J]. Advances in Neural Information Processing Systems, 2022, 35: 5982-5994.
- [23] Majumdar A, Aggarwal G, Devnani B, et al. Zson: Zero-shot object-goal navigation using multimodal goal embeddings[J]. Advances in Neural Information Processing Systems, 2022, 35: 32340-32352.
- [24] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.
- [25] Chaplot D S, Gandhi D, Gupta S, et al. Learning to explore using active neural slam[J]. arXiv preprint arXiv:2004.05155, 2020.
- [26] Gadre S Y, Wortsman M, Ilharco G, et al. Cows on pasture: Baselines and benchmarks for language-driven zero-shot object navigation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 23171-23181.
- [27] Cai W, Huang S, Cheng G, et al. Bridging zero-shot object navigation and foundation models through pixel-guided navigation skill[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 5228-5234.
- [28] Zhang R, Han J, Liu C, et al. Llama-adapter: Efficient fine-tuning of language models with zero-init attention[J]. arXiv preprint arXiv:2303.16199, 2023.
- [29] Liu S, Zeng Z, Ren T, et al. Grounding dino: Marrying dino with grounded pre-training for open-set object detection[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 38-55.
- [30] Kirillov A, Mintun E, Ravi N, et al. Segment anything[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 4015-4026.
- [31] Yamauchi B. A frontier-based approach for autonomous exploration[C]//Proceedings 1997 IEEE International Symposium on Computational Intelligence in Robotics and Automation CIRA'97.'Towards New Computational Principles for Robotics and Automation'. IEEE, 1997: 146-151.